

保障人民财产安全的林火守望者

——大兴安岭的林火预警系统

摘要

大兴安岭地区以其茂密的森林资源而著称，为当地居民、政府以及整个生态系统带来了显著的益处。然而，该地区山火频发，不仅威胁到人民的生命和财产安全，还对生态环境造成了严重的破坏。在人工智能和大数据技术迅猛发展的当下，利用这些先进的技术手段对大兴安岭地区的火灾规律进行建模和预测，无疑具有重大的现实意义和深远的影响。

为了实现对大兴安岭地区的山火预测，我们收集了该地区 2022 年的地形、植被、人为活动、气象条件以及历史火灾数据，并且使用 Python 和 Arcgis 软件进行了数据预处理，剔除了异常数据并且做了可视化分析。此外，为了确保数据分析的一致性，我们利用 Arcgis 软件的重采样功能，统一了各类数据的时间和空间分辨率。

在模型构建与比较方面，文章引入了 Logistic 回归、决策树回归器和梯度提升决策树三种机器学习算法模型。经过一系列的预测和效果比较，梯度提升决策树模型的预测精度达到了 87.97%，在三种模型中效果最佳。

进一步地，鉴于深度学习在捕捉数据特征方面的卓越能力，我们引入了 LSTM 神经网络，并创新性地提出了一种结合蒙特卡洛启发式优化的 Stochastic-LSTM 神经网络，借助启发式优化的思想实现了神经网络的自动调参和训练。预测结果显示，该神经网络的预测精度高达 91.63%，相较于传统机器学习模型，在大兴安岭地区的山火预测任务中展现出了更高的适用性和预测精度。

文章最后，我们对研究成果进行了全面而深入的总结，并针对研究中存在的不足提出了建设性的改进分析。基于本文建立的山火预测模型，我们为大兴安岭地区的火灾预防和控制工作提出了一系列切实可行的政策建议，旨在为该地区的可持续发展和生态保护提供科学指导和决策支持。

关键词：山火预测；Arcgis 数据处理；机器学习；LSTM；蒙特卡洛

目录

摘要.....	I
表格与插图清单.....	IV
一、 引言.....	6
(一) 研究背景以及意义.....	6
(二) 文献综述.....	7
1. 国外研究现状.....	7
2. 国内研究现状.....	9
(三) 研究内容.....	9
(四) 文章创新点.....	10
二、 数据获取和预处理.....	12
(一) 数据获取.....	12
1. 地形因子.....	12
2. 气象因子.....	13
3. 植被因子.....	14
4. 人为因子.....	14
5. 火灾数据.....	15
(二) 数据清洗和数据特征分析.....	16
1. 数据的缺失值、异常值处理.....	17
2. 影响因子的相关性分析.....	17
(三) 统一数据分辨率.....	18
1. 时间分辨率的统一.....	18
2. 空间分辨率的统一.....	19
(四) 数据拆分.....	19
三、 传统机器学习模型预测方法.....	20
(一) Logistic 回归算法原理.....	20
(二) 决策树回归器算法原理.....	20
(三) 梯度提升决策树算法原理.....	21
(四) 实验与分析.....	23

1. 实验评价指标.....	23
2. 模型效果对比.....	24
四、深度学习模型预测方法.....	26
(一) LSTM 神经网络算法原理	26
1. 遗忘门.....	26
2. 输入门.....	27
3. 输出门.....	27
(二) 启发式 LSTM 算法.....	28
(三) 模型训练与结果分析.....	30
五、总结与讨论.....	33
(一) 成果总结.....	33
(二) 改进分析.....	33
六、政策建议.....	35
(一) 加强技术应用与模型优化.....	35
(二) 强化数据收集与分析.....	35
(三) 提升应急响应与资源调度能力.....	35
(四) 增强公众教育与意识提升.....	35
(五) 推动跨部门合作与政策协调.....	35
(六) 促进科研与实践的结合.....	36
(七) 加强生态恢复与森林管理.....	36
参考文献.....	37

表格与插图清单

表 1. 数据获取表格

表 2. Logistic 回归算法伪代码

表 3. 决策树回归器算法伪代码

表 4. 梯度提升决策树算法伪代码

表 5. 模型评估的相关指标

表 6. 机器学习模型预测评价表

表 7. LSTM 神经网络算法伪代码

表 8. 深度学习模型预测评价表

图 1. 全国森林防火重点区布局图（局部）

图 2. 全国森林防火建设分区图（局部）

图 3. 全国森林火险等级区划图（局部）

图 4. CFFDRS 的系统结构图

图 5. 研究流程图

图 6. 海拔示意图

图 7. 坡度示意图

图 8. 坡向示意图

图 9. 日平均气温数据示意图

图 10. 2022 年 1 月份和 5 月份的植被数据示意图

图 11. 河流分布示意图

图 12. 道路分布示意图

图 13. 火灾强度的时间分布图

图 14. 2022 年 3 月火灾分布示意图

图 15. 火灾强度的分布直方图

图 16. 处理后的活在强度分布直方图

图 17. 火灾数据箱线图

图 18. 数据相关矩阵的热力图

图 19. 机器学习算法评估雷达图

图 20. 2022 年 3 月火灾风险预测图（GBDT）

图 21. LSTM 总体框架示意图

图 22. LSTM 遗忘门示意图

图 23. LSTM 输入门示意图 (1)

图 24. LSTM 输入门示意图 (2)

图 25. LSTM 输出门示意图

图 26. Stochastic-LSTM 神经网络算法执行程序图

图 27. 神经网络算法评估雷达图

图 28. 2022 年 3 月火灾风险预测图 (LSTM)

保障人民财产安全的林火守望者 ——大兴安岭的林火预警系统

一、引言

（一）研究背景以及意义

火灾作为一种自然灾害，对生态环境和人类社会都造成了巨大的影响。然而近年来全球气候变化导致火灾发生频率上涨。国家同样也察觉到了这一点，于是在十三五以及十四五会议中重点提出了相关的政策，同时通过阅读国家发布的森林火灾防治总方针“全国森林防火规划（2016—2025年）”，从几个森林火灾重灾区选择大兴安岭地区作为我们的研究对象，如图1，图2，图3所示，同时也不难发现大兴安岭地区的火情频繁所导致的预测结果分布过于广泛以至没有重点。



图1 全国森林防火重点区布局图（局部）

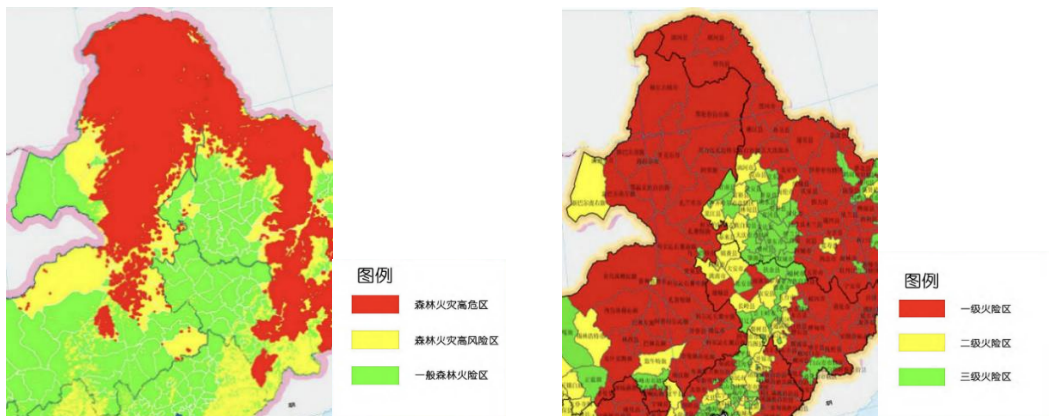


图2 全国森林防火建设分区图（局部）

图3 全国森林火险等级区划图（局部）

过于广泛的高危区域给及其有限的消防设备等的排布带来了很大的难题。同时为了响应国家对于森林火灾的声明，即“打小，打早，打了”，这一要求无法

被当下的技术很好的满足。精准预测火源发生的地点以及时间，也就能够早遏止火势发展，最大程度上减少各方面的损失，因而更加体现出林火预测的重要性。

大兴安岭地区作为中国重要的森林资源基地，同时也是森林火灾高发区，其火灾预测对于防灾减灾具有重要意义。本文通过统计建模选取更加广泛的数据指标，采用多元算法相结合的形式，可以更加有效预测小尺度范围内火灾发生的概率，为政府和相关部门提供更加严谨细致的科学依据，从而采取更有效的预防措施，例如，更加合理的安排消防资源等。

火灾预测研究不仅能够减少森林资源的损失，还能够保护生物多样性，维持生态系统的稳定。此外，我们的研究也是响应了国家相关政策的号召，如《“十四五”国家消防工作规划》和《关于全面加强新形势下森林草原防灭火工作的意见》，这些政策强调了预防为主、积极消灭、生命至上、安全第一的工作方针，全面推进防灭火一体化，持续优化体制机制，压紧压实防控责任，深化源头治理，加强基础建设，推动科技创新，提升队伍能力，有效防范化解重特大火灾风险，全力维护人民群众生命财产安全和国家生态安全。同时我们也注意到人民日报最新发表的文章“筑牢森林草原防火安全屏障”，其中再次强调了“处置在小”，安全高效“打早打小打了”这一要求，而本文的研究正是针对这一痛点进行了大兴安岭地区的森林火灾预测研究。

（二）文献综述

1. 国外研究现状

从 20 世纪 20 年代起，全球范围内的森林火灾预测研究逐渐兴起，尤其在北美和欧洲地区。美国在上世纪初期就开始探索火险等级，并制定了联邦防火法规。俄罗斯在沙俄时期就通过观察树枝的状态来预测火灾[1]。1928 年，加拿大科学家 Wright 发现，当空气湿度降至 50% 以下时，森林火灾的风险显著增加。1936 年，美国的 Gisborne 引入了火险因子的概念，并开发了多因素预测法。随后，加拿大和美国在森林火灾预测领域迅速发展[2]。

加拿大由于频繁发生森林火灾，因此非常重视火灾预测和防护。加拿大森林服务局自 20 世纪 20 年代起就开始研究火灾预测，以评估火灾行为。加拿大森林火险等级系统（CFFDRS）是一个成熟的预测系统，能够适应不同地区和全球尺度的需求[2]，系统结构图见图 4。该系统包含两个主要子系统：林火行为预报系统

(FBP) 和火险天气指标系统 (FW)。CFFDRS 在预测森林火灾时, 综合考虑气象、火源、地形和可燃物等多种因素。目前, 还有两个子系统正在开发中, 尚未形成全国性的系统。美国的国家火险等级系统 (NFDRS) 和 CFFDRS 是目前最为完善的森林火灾预测系统。

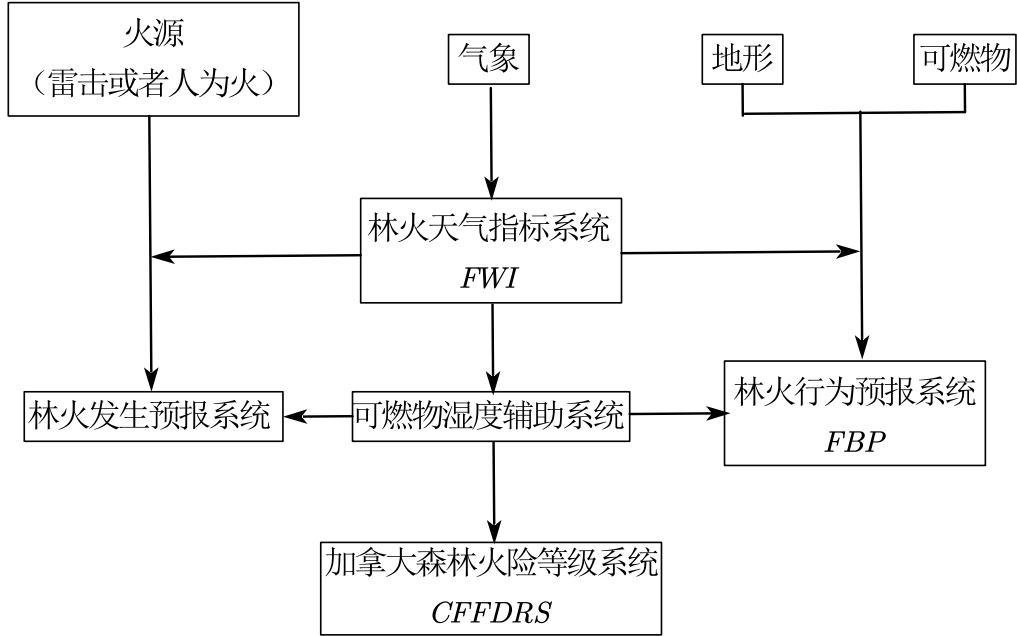


图4 CFFDRS 的系统结构图

近年来, 国外学者在森林火灾预测方法上趋向多元化。例如, Giménez 等人通过分析温度、湿度、降雨和风速等因素, 并运用支持向量机等算法, 提高了对小型火灾燃烧面积的预测频率[2]。Marco 等人研究了机器学习模型在评估人为因素引发的森林野火效果上的应用, 发现随机森林、增强回归树和支持向量机等算法能够提升预测精度。Jafari 等人利用爱尔兰的火灾卫星数据和地理数据, 通过 Logistic 回归和神经网络模型识别高风险火灾区域, 证明了神经网络在分类准确性上的优势。Abolfazl 等人基于伊朗海尔卡尼亚地区的火灾事件, 建立了空间数据库, 并对预测变量进行分类, 比较了四种混合人工智能模型在野火发生概率预测上的效果, 发现混合模型优于单一模型[2]。Wotton 等人使用泊松回归分析方法, 预测了加拿大安大略省由人类活动引发的森林火灾数量, 预测结果显示, 未来 20 年内该省由人类活动引起的森林火灾比例将显著增加。Marchal 等人通过分析魁北克南部阔叶林的火灾数据, 建立了泊松回归模型, 发现道路密度

是影响人为火灾频率的主要因素[1]。Plucinski 等人研究了澳大利亚西部森林管理区的野火，建立了负二项回归模型，用于预测日常火灾[1]。

2. 国内研究现状

中国的森林火灾预测研究始于 20 世纪 50 年代，主要基于国际上的林火预报系统进行改进。侯锡铭等人使用 Logistic 模型，结合大兴安岭地区的气象因子，建立了森林火灾预测模型[2]。田应福等人利用广义线性模型分析了日本森林火灾与气象因素的关系。胡林等人通过燃烧实验收集数据，并建立了房山地区的森林火灾数据库。郭朋勃等人研究了森林火灾的发生时间、原因、区域和次数，并结合天气条件进行预测[4]。张喆利用 3s 技术对太原市的火险因子进行建模。黄晓磊等人结合 GIS 和 AHP 方法[4]，建立了森林火险预测模型。谭三清等人根据国内火险等级标准，分析了广州市的气象和植被数据。王金荣等人使用 CFFDRS 系统对黑龙江省大兴安岭的雷击火进行建模。

以上为我国当前具有代表性的森林火灾预测预报研究方法，主要是通过收集研究区域相关森林火灾数据(包括数据记录、遥感图像等形式)[3]，并且挖掘相关气象数据、地形地貌数据、植被数据、人口数据等因素与森林火灾发生的关系，并采用相关回归分析、聚类分析、空间分析等方法对数据进行建模，建立相应的森林火灾发生预测模型，划定相应的火险等级，当前我国对森林火灾预测预报已经走上多元预测的道路。

(三) 研究内容

本文主要基于大兴安岭地区的地形、气象、植被、人为因子进行山火预测，我们首先获取了这些因子和山火数据，并且使用 Python 和 Arcgis 软件进行了数据预处理、统一精度和可视化分析，然后分别用机器学习方法和深度学习方法进行预测模型的训练，最后对全文进行总结并且依据预测模型对大兴安岭地区的山火防控提出了可行性政策建议，本文具体的研究内容以及流程如下图所示：

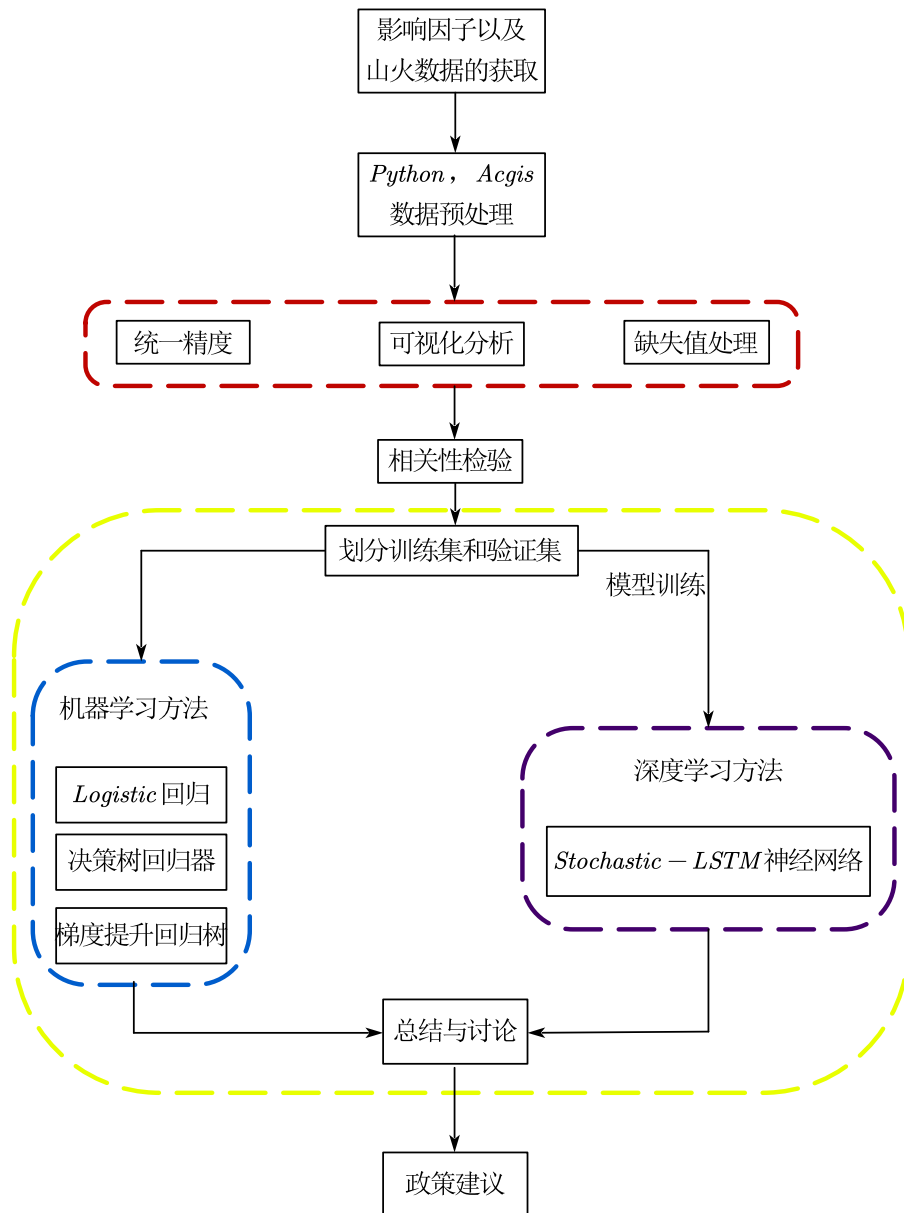


图5 研究流程图

（四） 文章创新点

1. 针对大兴安岭地区的火灾情况进行了具体研究

本文获取到了大兴安岭地区 2022 年的地形数据、植被数据、人类活动因子、气象因子和火灾数据，并且构建了模型进行大兴安岭地区的火灾预测，还根据预测的结果对大兴安岭地区的山火防控提出了可行性建议。

2. 使用了新时代的机器学习和深度学习方法对传统的山火问题进行了研究

机器学习和深度学习方法相比于传统统计方法可以更有效的捕捉各个影响因子和火灾数据之间的潜在联系，为火灾预测问题的研究带来新活力，本文通

过构建不同的机器学习和深度学习模型进行山火预测并进行横向对比，评价了不同模型在处理大兴安岭地区火灾预测问题上的表现。

3. 提出了一种结合了启发式优化算法的 LSTM 神经网络

在使用 LSTM 神经网络对山火数据进行预测时，引入了启发式优化算法，提出了一种可以自动调参的结合了蒙特卡洛启发式优化算法的 LSTM 神经网络，并将其命名为 Stochastic-LSTM 神经网络，经过验证，Stochastic-LSTM 神经网络相比于传统的机器学习方法在森林火灾的预测中具有更加出色的表现。

二、 数据获取和预处理

(一) 数据获取

有关森林火灾的影响因子比较广泛，这里将这些因子分为地形因子、气象因子、植被因子和人为因子四个部分，另外我们还需要获取大兴安岭地区的火灾数据，本片论文通过调研，获取了 2022 年 1 月 1 日到 2023 年 1 月 1 日的数据，数据获取表格如下所示：

表1 数据获取表格

数据类型	具体数据	网址	格式
地形因子	高程	https://www.gscloud.cn/	栅格
	坡度	https://www.gscloud.cn/	栅格
	坡向	https://www.gscloud.cn	栅格
	风速	https://data.cma.cn/	栅格
气象因子	降雨量	https://data.cma.cn/	栅格
	相对湿度	https://data.cma.cn/	栅格
	地表温度	https://data.cma.cn/	栅格
植被因子	MOD13A3	https://ladsweb.modaps.eosdis.nasa.gov/	栅格
人为因子	河流位置	https://www.gscloud.cn/	栅格
	道路位置	https://www.gscloud.cn/	栅格
火灾数据	火灾点	https://firms.modaps.eosdis.nasa.gov	栅格

1. 地形因子

本论文调查的目标是大兴安岭地区的相关数据，通过大兴安岭地区行政公署发布的相关文件 [5]，可以得知大兴安岭地区位于东经 121° 10′ 53″ 至 127° 01′ 21″，北纬 50° 07′ 02″ 至 53° 33′ 42″，包含 2 个县 1 个市 4 个区、29 个镇、10 个乡、4 个街道，通过这些信息，本文从地理空间数据云上下载了相关数字高程图，并使用 Arcgis 软件进行了边缘的划分，进而经过处理得到海拔、坡度、坡向这些数据，以下是一些 Arcgis 软件处理过后的地形因子数据图：

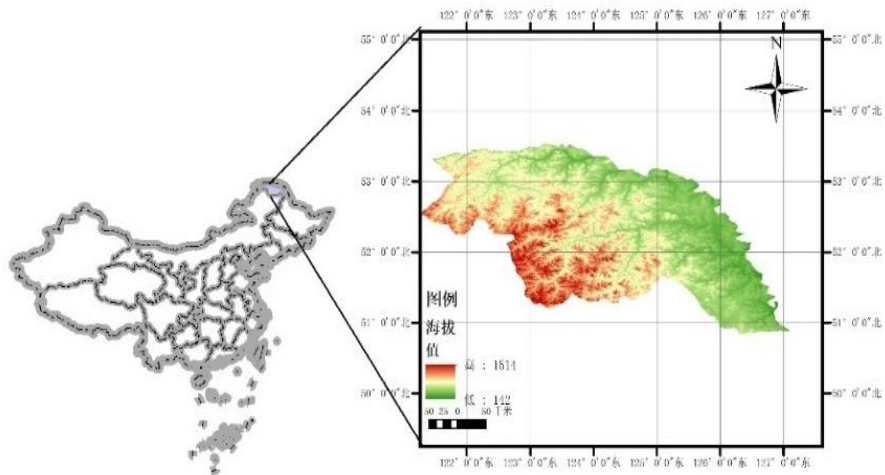


图6 海拔示意图

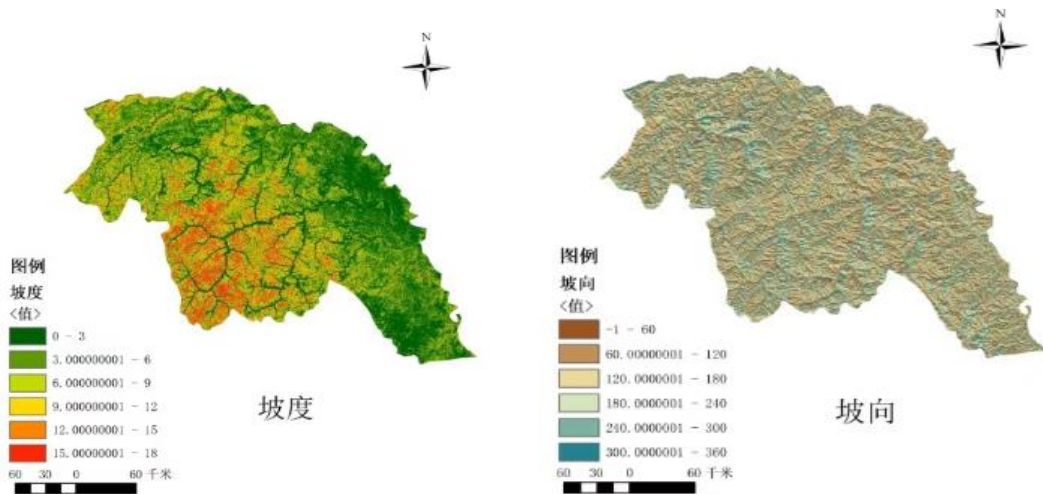


图7 坡度示意图

图8 坡向示意图

2. 气象因子

气象因子是引发山火的主要原因，也是引发山火的自然因子，是我们很难去掌控的因素。“天干物燥，小心火烛”，地表温度过高，降水量较少，就容易滋生火苗，而这种火苗的发现是十分困难的，如果已经滋生火苗之后还有源源不断的风力对火势进行助长，就会形成非常严重的火灾局面，这是我们都不想看到的。气象因子的影响作用十分重要，本文从国家气象信息中心搜集了大兴安岭地区2022年的风速、降雨量、相对湿度和地表温度气象数据，时间分辨率为每天，空间分辨率为1km*1km，并且使用 Arcgis 对获取到的气象站点相关数据进行光滑样条插值得到了各个区域的连续气象因子函数，后续又利用重采样得到一个区间内的气象因子来拟合各个区域的情况，如下图为2022年3月1日的大兴安岭地区日平均气温图：

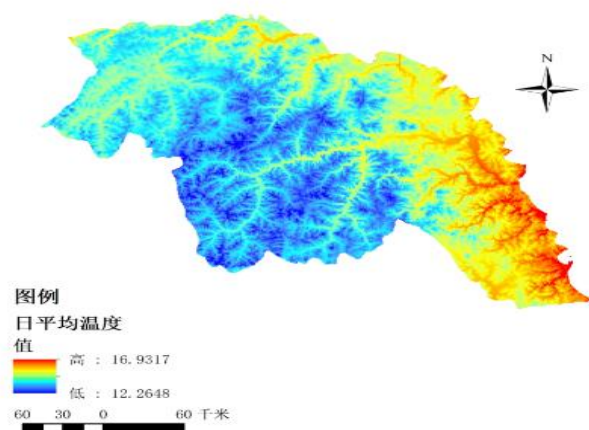


图9 日平均气温数据示意图

3. 植被因子

一个地区的植被因子会对火灾的产生造成巨大影响，植被的茂密与否、含水量的多少、植被的类型，都会对火灾的情况造成影响，本文选取的植被因子是归一化植被指数（Normalized Difference Vegetation Index，NDVI），可用于表征研究区域的植被生理状况、绿色生物量及植被生产力等，是植被宏观检测的重要指标，NDVI 的范围是 $[-1, 1]$ ，非植被区域的值接近 0 或是负值，密集植被区域的值则接近+1，本文选取 NASA 官网的 MODIS NDVI (即 MOD13 系列数据) 数据来表征 NDVI[6]，数据由 Terra 和 Aqua 卫星上的地球观测仪器获取，通过计算红光和近外红光的反射率差异和比值来得到，空间分辨率为 $1\text{km} \times 1\text{km}$ ，时间分辨率为一个月，2022 年 1 月和 5 月份的植被因子数据如下图所示：

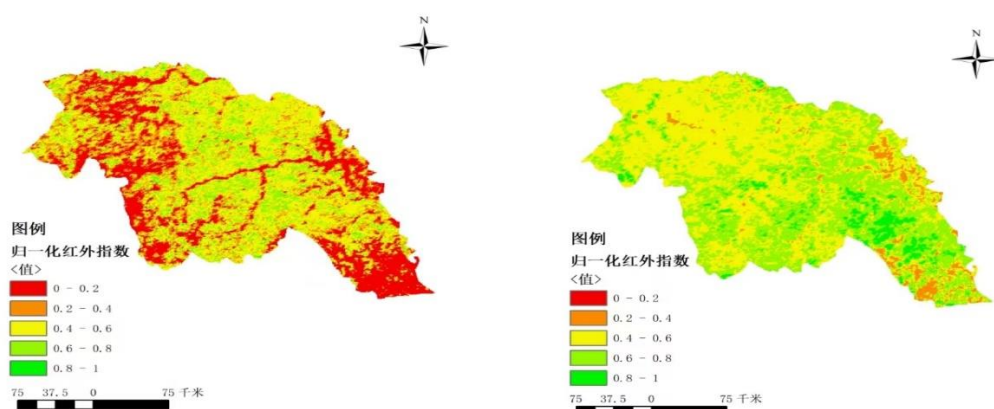




图10 2022 年 1 月份和 5 月份的植被数据示意图

4. 人为因子

人为因素也会对火灾的发生带来巨大的影响，人的流动活动情况具有随意性，

难以统计，但是人改造环境的活动可以被遥感数据捕捉到成为我们模型中的人为因子，例如人类建造的河流、道路位置，这些数据蕴含着一定的人为因素，可以为我们的模型带来更强的可解释性，人为因子的获取可以从地理空间数据云进行获取，精度为 1km*1km，以下为河流分布和道路分布示意图：



5. 火灾数据

NASA 提供了一个全球在线火灾地区数据分享平台，使用主动火灾产品套件以 MODIS 火灾和热异常算法为基础，以 12 小时以内的时间间隔系统的绘制全球的火灾活动图，清晰的记录的热异常发生的经纬度坐标，对应的火辐射功率以及置信度等数据，本文搜集了 VIIRS 传感器和 MODIS 传感器记录的大兴安岭地区在 2022 年所有的热异常点数据，其中有些数据近乎是常量，而且每天都是相同的数值，可能为当地的热发电厂或者一些其他稳定性热源，已经进行了剔除处理，2022 年的火灾点数据日期以及对应的热辐射强度如下图所示：




图13 火灾强度的时间分布图

为了更清楚的可视化，文章使用 Arcgis 软件画出了 2022 年 3 月份的火灾点的可视化地图，并使用克里金法对其进行空间预测背景填充，如下图所示：

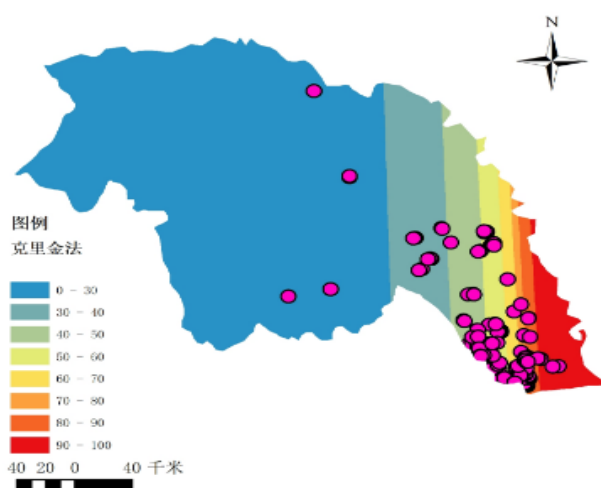


图14 2022 年 3 月火灾分布示意图

(二) 数据清洗和数据特征分析

获得到的数据是可能对山火造成重大影响的因子，但是各个因子的缺失值、异常值需要处理，因子之间的相互影响也不能忽视，有些因子的线性相关性比较强，即使拿来训练模型也不一定会带来精度的提升，甚至还会带来数据过拟合的缺点，所以数据清洗和数据的特征分析是后续构建模型的前提，将会直接决定模型的效果好坏与否，是必不可少的工作。

1. 数据的缺失值、异常值处理

本次实验的数据量庞大，将栅格型数据统一转换为表格型数据后，我们先检索了所有的缺失值，然后采取了剔除缺失值所在行的处理，保障了数据的完整性。

异常值的出现会对模型的构建造成巨大影响，我们根据各种数据的分布类型确定了合适的异常值探测和剔除方式，大部分因子的变化量不大，例如植被因子数据这种近似连续、而且分布近似可以看作正态分布的数据，我们可以直接使用箱线图这种方式进行异常值的探测和剔除。

对于火灾数据，因为是变化较大的离散变量，具有较高的正偏态程度（见图15），直接使用箱线图会剔除掉过多的数据，这明显是不合理的，因为其具有正偏态程度，所以我们采取取对数的方式将其进行一定程度的正态化，处理后的数据如图16所示，然后我们再对处理后的数据进行绘制箱线图，剔除掉异常数据，绘制的箱线图和异常点如图17。




图15 火灾强度的分布直方图




图16 处理后的火灾强度分布直方图

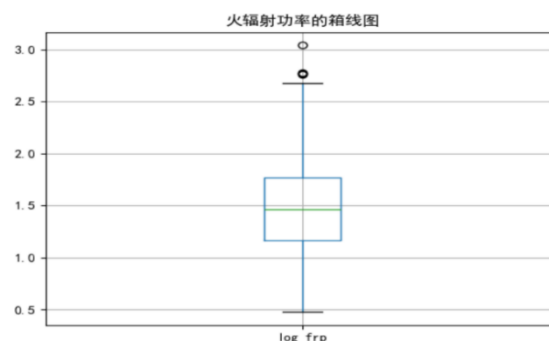


图17 火灾数据箱线图

2. 影响因子的相关性分析

不同的因子之间可能有线性相关性比较强的关系，这样的因子在训练模型时

不但不会起到促进模型精度提升的作用，反而会带来运算速度变慢甚至精度下降的问题，所以在构建模型之前对各个因子之间的相关分析是十分重要的过程，据研究，当变量的相关系数绝对值大于 0.8 时，说明二者之间存在着明显的相关关系[7]，相关性矩阵便是能查看变量相关关系的一个有利工具，本文使用 Python 求出各个因子及变量之间的相关性矩阵，并将其以热力图的形式呈现，热力图如下：




图18 数据相关矩阵的热力图

可见，热力图中不同指标的相关系数的绝对值最大不超过 0.4，即因子之间的相关线性关系较弱，对模型的预测都有贡献，所以不需要进行变量的剔除，在后续的训练中，我们将使用所有数据指标构成统一的数据集进行训练。

（三）统一数据分辨率

由于数据来源的网站不同，各自的分辨率也不同，为了训练时构造完整统一的数据集，我们需要统一所有数据的时间和空间分辨率。

1. 时间分辨率的统一

本文的目的是火灾预测，所以一切的数据都应以火灾数据的分辨率为主，火

灾数据的分辨率实则为 12 小时，但是中国大兴安岭地区的火灾治理相当不错，几乎没有同一天之内的同一地区两次重大火灾，所以我们将其分辨率当作一天进行处理，植被、地形、人为因子变化较小，所以将这些因子的一个月或半个月的时间分辨率提升到一天，这样我们就获得了时间分辨率为一天的数据组合。

2. 空间分辨率的统一

对于空间分辨率，我们需要综合考虑各种数据的精度，在进行数据量的大小和数据精度的统一之后，我们选取数据的空间分辨率为 1km*1km，使用 Arcgis 软件对数据进行重采样，得到了统一了空间分辨率的各种数据。

（四） 数据拆分

为了将数据应用于后续模型的训练和验证，我们先随机打乱了这些数据，尽量增大了数据的随机性，然后选取 70%和 30%的比例对数据进行切分，得到了模型数据的训练集和测试集，增大数据随机性这种方式可以使得模型能更好的捕捉到解释变量到因变量之间的映射关系，从而增强模型的准确性、适用性以及泛化能力[8]。

三、传统机器学习模型预测方法

本章节使用传统的机器学习方法对森林火灾进行预测，包含 Logistic 回归模型、决策树回归器模型和梯度提升决策树模型，先分别介绍了三者的算法基本原理，随后使用这些算法对数据做了仿真分析，最后对比了三种模型的结论。

（一）Logistic 回归算法原理

Logistic 回归是一种非常常见的分类模型，其非线性特征可以解决线性回归很多解决不了的问题，现在已经发展得相当成熟，可以称之为应用最广泛的分类、回归模型。

该模型使用 Sigmoid 函数最为基函数，可以把负无穷到正无穷的数值映射到从零到一的概率空间，数学表达式如下所示：

$$P_z = \frac{1}{1 + e^{-z}} \quad (1)$$

其中 P_z 表示映射到概率空间的事件发生概率， z 表示以解释变量为基底的线性组合，即：

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n \quad (2)$$

Logistic 算法的完成方式不唯一，可以使用最大似然估计进行模型的构造，也可以使用神经网络的方式令 Sigmoid 函数为激活函数来使得损失函数最小，这里给出一种 Logistic 回归的算法原理：

表2 Logistic 回归算法伪代码

算法:Logistic 回归	
输入：	训练数据集 $T = \{(x_1, y_1), \dots, (x_m, y_m)\}$ ，学习率 α ，最大迭代次数 T
输出：	Logistic 回归模型参数 θ
1:	初始化模型参数 θ
2:	for $t = 1, 2, \dots, T$ do
3:	计算模型预测值 $\hat{y} = \frac{1}{1 + e^{-z}}$
4:	计算损失函数 $L(y, \hat{y}) = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y})$
5:	计算梯度 g
6:	更新模型参数 $z = z - \alpha g$
7:	end for
8:	输出最终的模型参数 θ

（二）决策树回归器算法原理

决策树回归器主要指 CART(classification and regression tree)算法，

内部结点特征的取值为“是”和“否”，为二叉树结构，并主要应用于处理连续性数据。

与普通的决策分类树算法思想一致，决策树回归器算法的执行过程就是对数据和节点进行不断划分的过程，假设输入变量和输出变量为 X, Y ， Y 为连续性变量，给定对应的训练数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，使用决策树回归器对其进行自顶向下的贪婪思想递归构建二叉树，每次构建过程仅仅考虑当前最优，假设将当前训练集根据节点划分出两个区域后，两个区域的输出分别为 c_1, c_2 ，那么需要挑选分类区域的输出值和每个区域内的特征节点，构造目标函数：

$$\min_{j,s} \left[\min_{c_1} \text{Loss}(y_i, c_1) + \min_{c_2} \text{Loss}(y_i, c_2) \right] \quad (3)$$

其中损失函数 ($\text{Loss}(\cdot)$) 一般选择最小二乘损失函数，而这时对应的 c_1, c_2 恰好是各自区域内 Y 变量的均值，通过贪婪的思想进行不断的划分，直到达到固定迭代次数或者固定精度为止，决策树回归器的算法伪代码如下：

表3 决策树回归器算法伪代码

算法: 决策树回归器	
输入:	训练数据集 $D = \{(x_1, y_1), \dots, (x_m, y_m)\}$ ，树的最大深度 $\max Depth$
输出:	决策树 T
1:	初始化树的深度 $depth = 0$
2:	定义函数 $DecisionTreeRegressor(D, depth)$
3:	if D 中的所有的 y_i 相同或者 $depth = \max Depth$
4:	返回叶节点，将 D 中的平均 y_i 作为该节点的预测值
5:	else
6:	选择最优切分特征 j 和切分点 s
7:	根据 (j, s) ，将 D 划分为两个子集 D_1 和 D_2
8:	创建一个新的内部节点，通过贪婪算法将 (j, s) 作为切分条件
9:	对于每个子集调用 $DecisionTreeRegression(D_i, depth + 1)$ ， 并将返回的子树连接到内部的节点上
11:	返回新的内部节点
12:	调用 $DecidionTreeRegressor(D, depth)$ 生成决策树 T

(三) 梯度提升决策树算法原理

梯度提升决策树 (Gradient Boosting Decision Trees, GBDT) 作为一种强大的集成学习方法，是以决策树为基础的传统机器学习方法，现在的著名集成学习算法 XGboost、Catboost、LightGBM 都是以 GBDT 算法为框架并加以新思想的算法，性能和准确率十分优秀[9]。

梯度提升决策树以提升树（boosting tree）为原型，提升树也是一种集成算法，基学习算法为我们前面介绍过的 CART 回归树，并且使用前向分布算法来训练加法模型[10]，即：

$$f_M(x) = \sum_{i=1}^M f_t(x, \theta) \quad (4)$$

其中， $f_M(x)$ 就是最终模型， $\sum_{i=1}^M f_t(x, \theta)$ 是每棵 CART 回归树的模型， x, θ 为参数，即这个模型通过训练并组合多个弱学习器（CART 回归树），合成一个强学习器，这也是集成算法的思想。

提升树每次都能拟合上一次的模型中（上一代提升树）没有学习到的东西，可以对残差进行拟合，如何拟合残差呢？在这里我们使用残差平方和作为损失函数，即：

$$Loss = \sum_{i=1}^N L(y_i, f_t(x_i)) = \sum_{i=1}^N (y_i - f_{t-1}(x_i) - h_t(x_i))^2 \quad (5)$$

其中， $h_t(x_i)$ 为第 t 次迭代生成的回归树，我们的目的是使得损失函数最小，梯度提升决策树的方法就是引入梯度进行衡量，我们可以对损失函数进行一阶泰勒展开，有

$$\begin{aligned} Loss &= L(y, f_{t-1}(x) + h_t(x)) \\ &= L(y, f_{t-1}(x)) + \frac{\partial L(y, f_{t-1}(x))}{\partial f_{t-1}(x)} h_t(x) + O(h_t(x)) \end{aligned} \quad (6)$$

可以发现， $L(y, f_{t-1}(x))$ 是第 $(t-1)$ 次迭代的损失函数，如果令

$$h_t(x) = - \frac{\partial L(y, f_{t-1}(x))}{\partial f_{t-1}(x)} \quad (7)$$

那么，第 t 次迭代的损失函数相较于第 $(t-1)$ 次迭代的损失函数肯定要更小，因为通过泰勒展开我们得知减数是正数，而损失函数是残差平方和，具有非负性，其实只要令 $h_t(x)$ 的方向是该表达式即可，这样我们就得到了梯度提升决策树处理损失函数时采取的策略：每次迭代朝着梯度下降的方向前进，前进的步长可以由线性搜索算法确定。

梯度提升决策树的算法如下所示：

表4 梯度提升决策树算法伪代码

算法:梯度提升决策树		
输入:	训练数据集 $T = \{(x_1, y_1), \dots, (x_m, y_m)\}$, 最大迭代次数 T , 损失函数 L	
输出:	强化学习器 $f(x)$	
1:	初始化弱学习器	
	$f_0(x) = \arg \min_c \sum_{i=1}^m L(y_i, c)$	
2:	for $t = 1, 2, \dots, T$ do	
3:	对样本 $i = 1, 2, \dots, m$, 计算负梯度	
	$r_{ti} = - \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right]_{f(x) = f_{t-1}(x)}$	
4:	利用 (x_i, r_{ti}) ($i = 1, 2, \dots, m$), 拟合一颗 CART 回归树, 得到第 t 颗回归树, 其对于叶子节点区域为 $R_{tj}, j = 1, 2, \dots, J$ 。其中 J 为回归树 t 的叶子节点的个数	
5:	对叶子区域 $j = 1, 2, \dots, J$, 计算最佳拟合值	
	$c_{tj} = \arg \min_c \sum_{x_i \in R_{tj}} L(y_i, f_{t-1}(x_i) + c)$	
6:	更新强学习器	
	$f_t(x) = f_{t-1}(x) + \sum_{j=1}^J c_{tj} I(x \in R_{tj})$	
7:	end for	
8:	得到强学习器 $f(x)$ 的表达式	
	$f(x) = f_T(x) = f_0(x) + \sum_{t=1}^T \sum_{j=1}^J c_{tj} I(x \in R_{tj})$	

(四) 实验与分析

1. 实验评价指标

为了在验证集上评价各种模型的情况,我们选取了一些指标进行衡量,这些指标是每个模型的均方根误差(RMSE)、平均绝对误差(MAE)、R平方分数和准确率。RMSE和MAE可以反应模型在测试集上的模拟误差情况,R平方分数可以衡量模型与因变量之间的关联程度,范围为0到100%(0到1),准确率可以表示正确预测的样本占总体样本的个数,具体的计算公式见下表:

表5 模型评估的相关指标

指标	缩写	计算公式
均方根误差	$RMSE$	$\sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$

平均绝对误差	MAE	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $
R 平方误差	R^2	$1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$
准确率	$Accuracy$	$\frac{TP + TN}{TP + TN + FP + FN}$

2. 模型效果对比

通过分别对处理好的数据集进行 Logistic 回归、决策树回归器、梯度提升决策树的模型训练，我们获得了各个模型的评价指标，具体情况如下表所示：

表6 机器学习模型预测评价表

模型	$RMSE$	MAE	R^2	$Accuracy$
Logistic 回归	40.63	19.97	0.7574	0.6863
决策树回归器	27.63	14.97	0.9060	0.7833
GBDT	21.22	7.25	0.9367	0.8797

为了更清晰的显示这些评价指标，将其绘制成雷达图的形式，并将 R^2 和 $Accuracy$ 指标乘 100 处理得到模型得到新的指标（即它们的百分比数位），使得这两个指标在雷达图中更加容易被分辨，雷达图如下图所示：

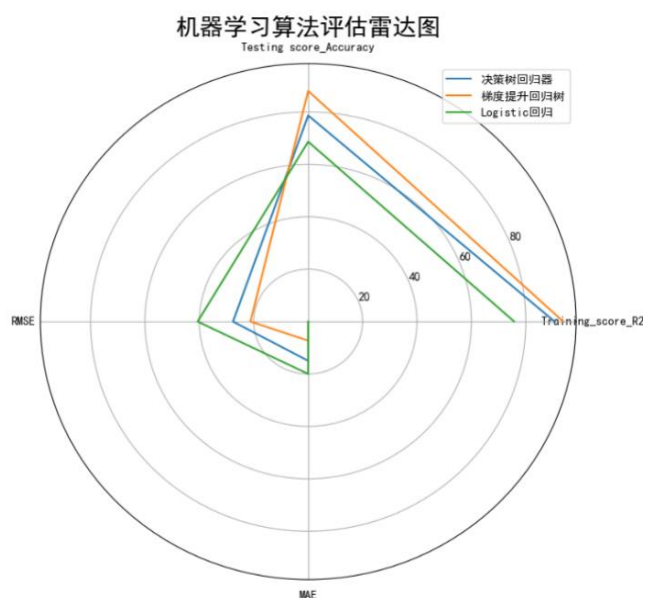


图19 机器学习算法评估雷达图

可以看到，针对于大兴安岭地区的山火预测，梯度提升决策树在训练集和预测集上的精度最高，误差指标也最小，决策树回归器和 Logistic 回归次之，在这

三种机器学习模型中，梯度提升决策树是最适合进行大兴安岭地区山火预测的机器学习算法，Logistic 回归的预测精度最低，仅仅为 0.6863，不适合进行山火方面的预测。

我们将 2022 年 3 月份的相关数据整理成数据集，时间分辨率为天，空间分辨率为 1km*1km，当作输入数据应用于梯度提升决策树模型，并将预测输出放到 Arcgis 软件中以热力图的形式显示出这一个月内大兴安岭地区的火灾风险分布图，如图 20 所示。

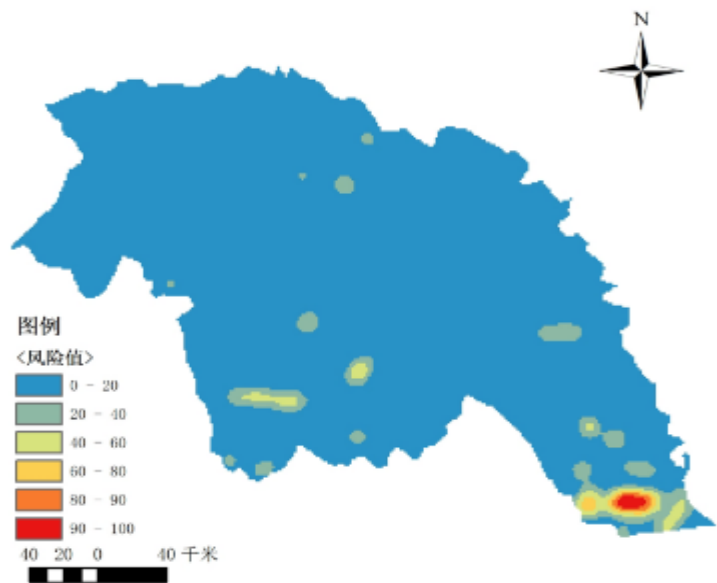


图20 2022 年 3 月火灾风险预测图（GBDT）

与图 14 对比，火灾点大致吻合，但是多出了一些低风险区域，可见预测模型对于火灾情况具有预知和指导作用。

四、深度学习模型预测方法

传统机器学习方法可以比传统统计学方法更有效的给出预测模型，但是其在特征的提取上还是具有一定的局限性，对特征工程的水平要求很高[11]，而且泛化能力较弱，新型机器学习里的深度学习便可以很好的解决这些问题，其不需要手动特征工程，而且具有很强的泛化能力，可以更好的对山火特征进行提取和分析。本章节介绍了长短时记忆神经网络的算法原理，而且结合启发式优化算法提出了 Stochastic-LSTM 神经网络的概念，并使用该神经网络应用于火灾预测，与传统的机器学习方法进行了对比。

（一）LSTM 神经网络算法原理

LSTM (long short-term memory, 长短时记忆) 神经网络，在 1997 年被提出，主要解决了长时间序列在训练过程中的梯度消失和梯度爆炸问题，具有更好的记忆性，因其独特的门特性比一般的 RNN (Recurrent Neural Network, 循环神经网络) 在处理长时间序列时表现的更加优秀[12]。

下面来通过对 LSTM 神经网络的单元内部架构的描述来介绍 LSTM 神经网络的算法原理，LSTM 神经网络的整体单元架构如下图所示：




图21 LSTM 总体框架示意图

可以看到，在每一个单元内，有三列纵向的函数处理操作，这是 LSTM 单元的三个函数层，对应三个函数门：遗忘门，输入门和输出门：

1. 遗忘门

LSTM 神经网络被用于处理长时间序列，所以当数据量非常大时进行数据的丢弃（遗忘）是必要的，如下图所示，每一个单元接受一个新的数据输入和上一个单元的输出，并且根据这些信息使用 Sigmoid 激活函数决定遗忘掉哪些信

息，通过这种遗忘整合的方式，使得 LSTM 单元可以更好的进行长时间序列的处理。遗忘门的处理公式为（其中的符号已经标注在图 22 中）：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (8)$$

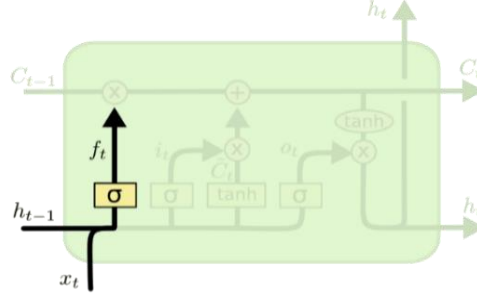


图22 LSTM 遗忘门示意图

2. 输入门

对于信息的处理不能只剩遗忘，还必须有输入和记忆，LSTM 有独特的记忆单元，可以选择性的接受输入信息，通过图 23 的 LSTM 输入门示意图可以看到

$$\begin{aligned} i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ \tilde{C}_t &= \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \end{aligned} \quad (9)$$

当前接受到的信息为 \tilde{C}_t ， i_t 为选择接受这部分信息的比例，二者相乘就是这次单元处理中需要记忆的信息，可以在图 24 中看到，遗忘门的权重被乘在上一个单元的输上，达到了遗忘的作用，这次输入又加在单元的总线上，起到了数据的选择性添加作用，即“记忆”的作用。




图23 LSTM 输入门示意图（1）




图24 LSTM 输入门示意图（2）

3. 输出门

上述的遗忘门和输入门已经完成了对记忆(数据)的更新操作，在这一个 LSTM 单元中还需要有传给下一级的输出，这就构成了输出门，可以在图 25 中看到，输出门中对数据的两个操作：

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (10)$$

$$h_t = o_t * \tanh(C_t)$$

其中 o_t 作为这一单元的输出，并没有输出所有处理后的数据，而是同样使用 Sigmoid 的激活函数进行处理后与现有记忆信息的 \tanh 激活函数处理后的信息进行相乘，而后传入下一个 LSTM 单元，做到了选择性输出的结果。




图25 LSTM 输出门示意图

通过上述对 LSTM 的特殊门处理的描述，我们了解到了 LSTM 对数据的特殊性记忆处理，其存在独立的记忆单元，存在对数据的选择性输入、输出和遗忘的功能，这也是 LSTM 神经网络能够胜任处理长时间序列的关键，下面根据 LSTM 算法原理，给出 LSTM 算法执行过程的伪代码：

表7 LSTM 神经网络算法伪代码

算法 LSTM 神经网络	
输入：	输入序列 $x = (x_1, x_2, \dots, x_T)$ ，初始化隐藏状态 h_0 和单元状态 c_0
输出：	输出序列 $y = (y_1, y_2, \dots, y_T)$
1:	for $t = 1, 2, \dots, T$ do
2:	计算输入门 $i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + b_i)$
3:	计算遗忘门 $f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + b_f)$
4:	计算输出门 $o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + b_o)$
5:	计算候选单元状态 $\tilde{c}_t = \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c)$
6:	更新单元状态 $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$
7:	更新隐藏状态 $h_t = o_t \odot \tanh(c_t)$
8:	计算输出 $y_t = \sigma(W_{hy}h_t + b_y)$
9:	end for

(二) 启发式 LSTM 算法

LSTM 算法固然强大，但也不是完全自治的算法，算法的运行还需要 LSTM 神经网络超参数的设置，即隐含层神经元数、学习率、训练次数的设置，若是超参数设置的不合理，LSTM 神经网络也有可能捕捉不到正确的特征信息，从而得到预测精度比较差的模型。

一种可行的解决方法就是使用优化算法在神经网络训练的过程中不断优化超参数、直到达到网络的最优化和超参数的最优化[13]，启发式优化算法便是一种容易理解而又效率不低的优化算法，是一种依据生活经验观察和基于直观的优化算法，例如模拟退火算法、禁忌搜索算法、蚁群算法等等。

优化的目的是找到一个函数的全局最小值（或最大值），启发式优化算法是优化算法里比较容易理解的一个分类，本质上就是有策略的随机取点配合择优选择机制，在此本质上根据不同的策略，便可以构造出不同的启发式优化算法，例如模拟退火算法的随机选择策略就是在一定的概率下概率接受每一轮迭代的最优解，这样既保证了目标函数总体在向最优解靠近，又可以在一定程度上避免陷入局部最优解；蚁群优化算法的随机选择策略就是在初始化时生成大量随机点，然后每次更新最优点的方向，所有点在一定的概率的驱动下向当前全局最优点和局部最优点靠拢，因为点数庞大，也可找到效果不错的解。模拟退火算法和蚁群优化算法的择优策略公式如下所示：

模拟退化算法择优策略：

$$P = \begin{cases} 1, & E_{t+1} < E_t \\ e^{-\frac{(E_{t+1}-E_t)}{kT}}, & E_{t+1} \geq E_t \end{cases} \quad (11)$$

蚁群优化算法择优策略：

$$p_k(i, j) = \begin{cases} \frac{[\tau(i, j)]^\alpha [\eta(i, j)]^\beta}{\sum_{u \in J_k(i)} [\tau(i, u)]^\alpha [\eta(i, u)]^\beta}, & \text{如果 } j \in J_k(i) \\ 0, & \text{其他} \end{cases} \quad (12)$$

启发式算法具有极高的随机性和有效性，哪怕是简单的蒙特卡洛真随机取点，只要随机次数足够多，配合合理的最优选择策略，也可以找到效果不错的最优解。可见，启发式算法在优化比较庞大的问题上，因具有特定的随机取点策略，是十分有效的，是一种兼具冒险性和稳健性的优化算法。

本文将启发式优化算法与 LSTM 神经网络进行融合，构造出全自治的启发式 LSTM 神经网络，由于启发式算法无非是随机取点和择优选择，在模拟次数足够大的时候，很大概率可以找到很好的局部最优解甚至全局最优解，所以本文选取最朴素的蒙特卡洛真随机取点方法和绝对型择优取点策略作为 LSTM 神经网络的启发式优化算法，并将其命名为 Stochastic-LSTM 神经网络，绝对型取点策略如下公式所示：

$$x_k = \begin{cases} x_k, & f(x_k) < f(x_{k-1}) \\ x_{k-1}, & f(x_k) \geq f(x_{k-1}). \end{cases} \quad (13)$$

即如果当前点的解比上一个点的解更优，更新迭代位置为当前点，否则以上一个点为当前迭代位置，继续进行下一轮迭代，这种策略可以保证最后的超参数一定比初始迭代的超参数效果更好，具有稳健性，但是有可能陷入局部最优解，这也是所有启发式优化算法都不能避开的问题，根据蒙特卡罗随机方法、最优取点策略和 LSTM 神经网络算法原理可以得到如下 Stochastic-LSTM 神经网络算法执行程序图：

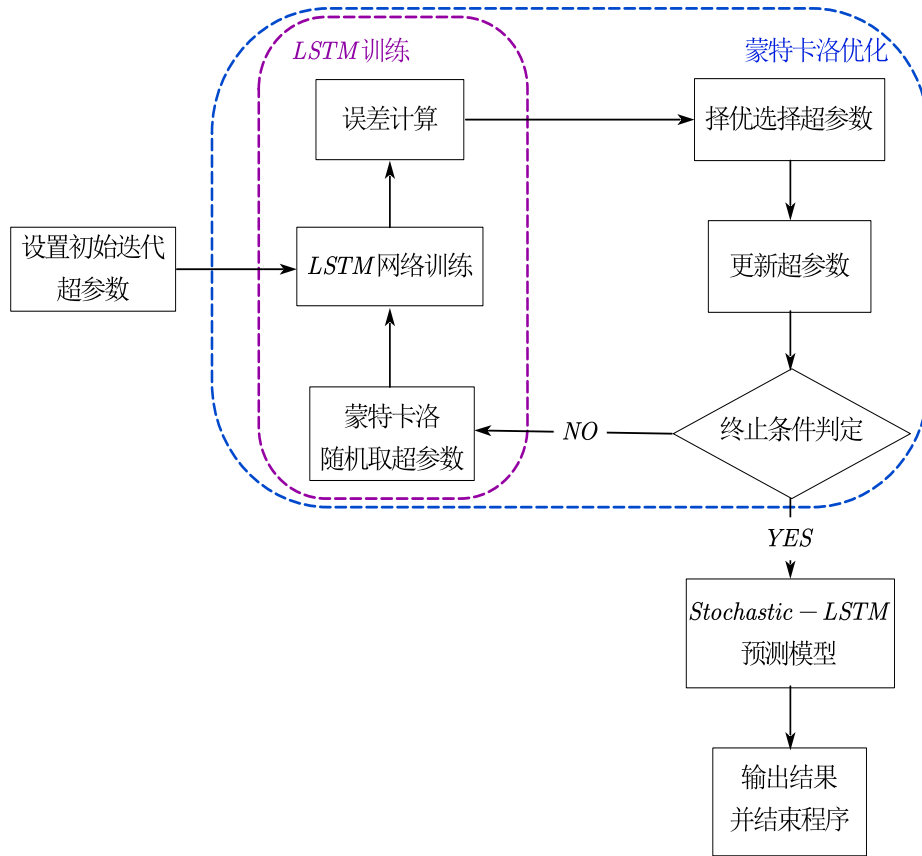


图26 Stochastic-LSTM 神经网络算法执行程序图

(三) 模型训练与结果分析

通过应用 Stochastic-LSTM 神经网络算法进行火灾预测，按照已经设置的评价指标，我们得到了以下结果表格（为了便于对比，我们在结果中复制了前一个章节中传统机器学习方法的预测结果）：

表8 深度学习模型预测评价表

模型	$RMSE$	MAE	R^2	$Accuracy$
Stochastic-LSTM	14.63	5.97	0.9745	0.9163
Logistic 回归	40.63	19.97	0.7574	0.6863

决策回归器	27.63	14.97	0.9060	0.7833
GBDT	21.22	7.25	0.9367	0.8797

为了更加直观的对比各个评价指标，将表格以雷达图的形式绘制出来， R^2 和 $Accuracy$ 指标的处理与上一章节相同，如下图所示：




图27 神经网络算法评估雷达图

可见，Stochastic-LSTM 神经网络在训练集拟合精度和预测集预测精度都要比上一章节所述的机器学习算法效果好，神经网络确实能更有效的捕捉数据内隐含的映射关系，特别是在预测集上的预测精度已经达到了 91.63%，只要数据充足，便可以将其应用于实际的山火风险预测项目当中，具有很高的可行性。

采用和上一章节同样的 2022 年 3 月份数据集当作输入数据应用于 Stochastic-LSTM 神经网络模型，并将预测输出放到 Arcgis 软件中以热力图的形式显示出这一个月大兴安岭地区的火灾风险分布图，如图 28 所示。




图28 2022年3月火灾风险预测图 (LSTM)

该风险预测图可以更清晰的看到模型预测的结果，与图 14 中实际的火灾情况对比也大致吻合，但是相比于实际的火灾情况和图 20 中 GBDT 模型的预测，该火灾风险预测图中有更多的预警区域，并且比较有趣的事情是，LSTM 模型和 GBDT 模型都在图中标出了几块大致相同的风险区，但是这些风险区却没有包含该月份真实的火灾点，这可能暗含的该月份当地隐含的一些火灾情况，对应急响应与资源调度具有实际的指示意义，可以帮助当地政府和人民更好的应对火灾这一事件的发生。

五、总结与讨论

火灾数据是无规律性、多元性、成因复杂的非常规数据，使用传统的统计学方法无法很好的捕捉到各种数据的特征，而深度学习方法却能够较好的提取出这种非常规数据的特征，从而显著的提高火灾预测模型的准确度，如果将这项技术加以特殊性改进，训练出适合各个地区的火灾预测模型，将会极大程度的减轻火灾带来的损失，下面是对本篇文章的数据处理和模型构建方面的成果总结和改进分析：

（一） 成果总结

收集并且使用 Arcgis 软件处理了森林火灾的影响因子。本篇论文综合调研了很多文献资料，从大量的网站实际下载并且模拟了大量数据，最后选择了可信度最高且质量最好的数据进行处理和训练模型，Arcgis 软件也在这个过程中起到了重要的作用，因为有关山火因子的数据几乎都是以栅格形式储存的，Arcgis 为处理栅格类型的数据提供了便利的环境，使得数据可以转化为统一格式和统一分辨率，并且还能做数据的可视化分析。

使用了传统的机器学习方法对火灾进行预测。总结了 Logistic 回归、决策树回归器、梯度提升决策树的算法原理，给出了清晰明了的机器学习算法伪代码，并且将这些算法应用于实际的山火预测当中，横向对比了这三种机器学习方法在山火预测问题中的表现，得出梯度提升决策树的预测效果最好的结论。

提出了一种结合了蒙特卡洛启发式优化算法的 Stochastic-LSTM 神经网络算法，并将其应用于火灾预测。虽然神经网络概念的提出已经有很长一段时间，但是将其用于火灾的分析和预测方面的学者并不算太多，而火灾情况是我们需要花费大精力去研究的事件。本文从 LSTM 单元架构的角度介绍了 LSTM 神经网络对数据独特的选择性记忆功能，并且引入了蒙特卡洛启发式优化算法来更新 LSTM 神经网络的超参数，给出了 LSTM 神经网络的伪代码和 Stochastic-LSTM 神经网络的程序执行图，并使用该模型对 2022 年 3 月的火灾数据进行了预测，将结果以热力图的形式呈现。

（二） 改进分析

虽然本文在数据的获取和处理阶段提到了人为因子，但是并没有更多的讨论人类活动因素对森林火灾的影响。人类在森林附近开发的大规模项目、去山上游

玩的“驴友”，甚至是地区政府采取的治理森林火灾的政策，都属于人类活动因素，这些因素具有难以量化性、随机性的特点，使得难以纳入模型的框架中，但是确确实实对森林火灾的产生或者消灭造成了很大的影响。

没有针对具体事件对神经网络进行特定优化，从而将时空特征有效的联合起来。神经网络虽然具有很强的处理各种事件的能力，但是如果针对大兴安岭地区的森林火灾这一具体事件，有目的性的对神经网络的模型和架构进行优化，使得其能更好的捕捉有关火灾数据的时空特征，将会得到更稳健、可行的神经网络算法模型，获得更高的预测精度，具有更高的实际使用价值。

六、政策建议

近年来，大兴安岭地区政府对森林火灾这种危害极大的自然灾害愈加重视，通过 2022 年的火灾数据也可以看到，森林火灾的热辐射强度在不断的减弱，这说明当地政府采取了有效的措施对火灾进行预防和及时止损：“三单一承诺”工作机制、“两书一函”制度、“四个一律”等等制度[14]，都彰显了大兴安岭地区对火灾防控的重视，论文在建立火灾预测模型的基础之上，为大兴安岭地区的火灾的预防与控制提出以下政策建议：

（一）加强技术应用与模型优化

1. 利用 Stochastic-LSTM 神经网络等人工智能手段对火灾发生的概率、时间和地点进行高精度预测。

2. 定期更新和优化预测模型，以适应环境变化和新的数据输入。

（二）强化数据收集与分析

1. 建立一个全面的森林火灾数据收集系统，包括气候条件、植被类型、人类活动等数据。

2. 利用大数据和人工智能技术，深入分析数据，以识别火灾风险模式和潜在的高风险区域。

（三）提升应急响应与资源调度能力

1. 根据 Stochastic-LSTM 等人工智能模型的预测结果，制定灵活的应急响应计划，包括快速的消防队伍部署和资源调度。

2. 建立一个集中化的应急指挥中心，实现跨部门的协调和沟通。

（四）增强公众教育与意识提升

1. 开展以数据驱动的防火教育活动，利用预测模型的结果来指导公众如何预防火灾和在火灾发生时如何安全行动。

2. 利用社交媒体和公共广播系统，定期发布火灾风险预测和安全指南。

（五）推动跨部门合作与政策协调

1. 建立一个多部门协作机制，包括林业、气象、消防和地方政府等，共同制定和实施火灾预防措施。

2. 制定统一的火灾预防和应急响应标准，确保所有相关部门遵循相同的操作程序。

（六） 促进科研与实践的结合

1. 鼓励科研机构与地方政府合作，将最新的科研成果应用于实际的火灾预防和控制工作中。
2. 定期举办研讨会，分享可行实践方式和技术创新方法。

（七） 加强生态恢复与森林管理

1. 实施可持续的森林管理措施，如合理规划森林结构，减少易燃植被的密度，提高森林对火灾的抵抗力。
2. 在火灾易发区域实施生态恢复项目，如植树造林和湿地恢复，以改善生态环境并降低火灾风险。

参考文献

- [1] 宋志龙, 王海晖, 吴泽鹏, 杨峰峰, 靳邦鑫, 王振师. 西方国家森林火灾研究架构与技术建树[J]. 林业世界, 2022, 11(2): 47-55. DOI: 10.12677/wjf.2022.1120061.
- [2] 王秋华, 王 劲, 王亚荣, 邢付吉. 国内外重大森林火灾研究进展[J]. 消防科学与技术, 2022, 41 (10): 1455-14592.
- [3] 覃先林, 李晓彤, 刘树超, 刘倩, 李增元. 中国林火卫星遥感预警监测技术研究进展. 遥感技术与应用, 2020, 24(5): 511-5203.
- [4] 森林草原火灾监测技术研究现状和展望. 中国林业科学研究院林业科技信息研究所《世界林业研究》, 2021-09-104.
- [5] 行政区划_大兴安岭地区行政公署 (dxa1.gov.cn)
- [6] 孙锐, 陈少辉, 苏红波. 2000—2016 年黄土高原不同土地覆盖类型植被 NDVI 时空变化[J]. 地理科学进展, 2019, 38(08): 1248-1258.
- [7] 汪冬华. 多元统计分析与 SPSS 应用[M]. 上海: 华东理工大学出版社, 2010.
- [8] 杨慧中, 卢鹏飞, 张素贞, 等. 网络泛化能力与随机扩展训练集[J]. 控制理论与应用, 2002(06): 963-966.
- [9] 李航, 统计学习方法(第二版)[M], 清华大学出版社, 2019.
- [10] 成佩, 孟勇. 集成学习方法的应用与比较[J]. 统计与决策, 2023, 39(23): 28-33. DOI: 10.13546/j.cnki.tjyjc.2023.23.005.
- [11] 吴勇宣, 韩珣, 谢志伟, 等. 自动化特征工程综述[J]. 智能计算机与应用, 2023, 13(03): 254-259.
- [12] 周志华, 机器学习(第二版), 清华大学出版社, 2019.
- [13] 陆敏芳. 给予神经网络的启发式优化算法研究[D]. 济南大学, 2023. DOI: 10.27166/d.cnki.asdcc.2022.000174.
- [14] 黑龙江省人民政府, 黑龙江省人民政府 2023 年森林草原防火命令-黑龙江人民政府网 (hlj.gov.cn)